

Semantic Text Similarity (STS)

➡ Calculer la similarité sémantique entre deux documents
Chaque paire de documents est annotée de 0 (pas du tout similaire) à 5 (très similaire)

Phrase 1	Phrase 2	Similarité
A man is smoking.	A man is skating.	0.500
A panda is sliding down a slide.	A panda slides down a slide.	4.600
A person is peeling an onion.	A person is peeling an eggplant.	2.000


- Applications:
- service client (la question a-t-elle déjà été posée ?)
 - engins de recherche (StackOverflow...)

Dataset


Train	Validation 10-15%	Test
5703 échantillons		1403 échantillons

Données d'entraînement

- Taille du vocabulaire (*avant pré-traitement*) :
- Longueur de la phrase la plus courte :
- Longueur de la phrase la plus longue :
- Répartition des scores homogène :




Pipeline générale



Mesure de corrélation


➡ Pour chaque paire de phrase de l'ensemble de test, trouver un coefficient de corrélation, non pas entre les scores mais entre les rangs de ces scores



Nos modèles

Embeddings de mots	Embeddings de phrases	Estimateur final	Corrélation Spearman
BERT pré-entraîné	Somme	Similarité Cosinus	0,41
(One-hot)	TF-IDF + SVD	Multi-Layer-Perceptron	0,44
(One-hot)	TF-IDF	Multi-Layer-Perceptron	0,44
Word2Vec (avec stopwords)	LSTM	Distance Manhattan	0,72
Word2Vec	Somme	Similarité Cosinus	0,73
(One-hot)	Fréquence	Similarité cosinus	0,73
Word2Vec	LSTM	Similarité Cosinus	0,74
(One-hot)	TF-IDF	Similarité Cosinus	0,76
Word2Vec (sans stopwords)	Somme	Similarité cosinus	0,78
BERT fine-tuned	Somme	Similarité Cosinus	0,89

Méta-régression



Modèle retenu: BERT

- Préparation du modèle:
 1. Transfer Learning : utilisation d'un BERT pré-entraîné sur wikipédia anglais (BERT large, uncased)
 2. Adaptation du modèle à la tâche STS : fine-tuning sur l'ensemble d'entraînement

- Utilisation du modèle:



Puis similarité cosinus entre les embeddings de chaque phrase

Systèmes concurrents

Système	Spearman
RoBERTa	90,2
XLNet	91,1
AlBERT	92